Министерство науки и высшего образования Российской Федерации

Федеральное государственное автономное образовательное учреждение высшего образования

«Новосибирский национальный исследовательский государственный университет»

(Новосибирский государственный университет, НГУ)

Механико-математический факультет

Согласовано

Декан факультета _____

«___» _____ 2026 г.

РАБОЧАЯ ПРОГРАММА ДИСЦИПЛИНЫ

Анализ данных

Образовательная программа: Прикладная математика и информатика

Направление подготовки: 01.03.02 Прикладная математика и информатика

Направленность (профиль): Прикладная математика и информатика

Уровень образования: бакалавриат

Форма обучения: очная. Язык реализации: русский

Семестр изучения: 4. Трудоемкость: 3 зачетные единицы, 108 академических часов

Разработчики: преподаватель дисциплины «Анализ данных»

Ф.И.О., должность _____ Подпись _____

Новосибирск, 2026

Аннотация к рабочей программе дисциплины

Дисциплина «Анализ данных» посвящена полному циклу работы с табличными данными: от постановки исследовательского вопроса и проверки качества исходной информации до построения базовых моделей и представления выводов. Основное внимание уделяется обоснованию аналитических решений, корректной оценке качества и воспроизводимости вычислительного эксперимента.

Курс включает шесть разделов: структура данных; разведочный анализ; предобработка; базовые модели; оценка качества; воспроизводимое исследование. Лекционный материал закрепляется практическими заданиями с использованием Python и Jupyter Notebook. Обучающиеся выполняют подготовку данных, сравнивают методы и оформляют результаты в виде аналитических записок и итогового проекта.

Дисциплина изучается в четвертом семестре. Общая трудоемкость составляет 3 зачетные единицы (108 академических часов), включая 18 часов лекций, 36 часов практических занятий и 54 часа самостоятельной работы. Промежуточная аттестация проводится в форме экзамена. Результаты обучения соотнесены с компетенциями ОПК-1 и ОПК-3 выбранной образовательной программы.

1. Цели освоения дисциплины

Цель дисциплины — сформировать способность самостоятельно проводить обоснованный анализ табличных данных, строить базовые математические модели и критически оценивать полученные результаты.

Для достижения цели решаются следующие задачи:

- освоение методов проверки качества данных, описательной статистики и визуального исследования;
- освоение приемов предобработки, построения признаков и организации корректного вычислительного эксперимента;
- приобретение навыков выбора моделей и метрик, анализа ошибок и представления воспроизводимых результатов.

2. Место дисциплины в структуре образовательной программы

Курс предназначен для обучающихся направления 01.03.02 «Прикладная математика и информатика» и изучается после освоения основ программирования, линейной алгебры, математического анализа и вводного курса теории вероятностей.

Входные требования: умение писать программы на Python, работать с функциями и коллекциями, понимать векторно-матричные операции и основные вероятностные понятия. Перед началом практических работ проводится входное задание на загрузку и обработку таблицы.

Результаты дисциплины используются при дальнейшем изучении машинного обучения, прикладной статистики и методов математического моделирования, а также при выполнении учебных исследовательских проектов. Основной формат занятий — сочетание лекций, практической работы за компьютером и самостоятельного анализа данных.

3. Перечень планируемых результатов обучения по дисциплине, соотнесенных с результатами освоения образовательной программы

ОПК-1. Способен применять фундаментальные знания, полученные в области математических и (или) естественных наук, и использовать их в профессиональной деятельности.

ОПК-3. Способен разрабатывать и анализировать математические модели, применять методы математического моделирования в профессиональной деятельности.

Планируемый результат обучения	**Форма проверки**
1. ОПК-1: знает методы описательной статистики, типы признаков и принципы проверки качества данных.	Теоретические вопросы; аналитическая записка по разведочному анализу.
2. ОПК-1: объясняет назначение преобразований признаков, правила разделения данных и причины утечки информации.	Защита практической работы по предобработке.
3. ОПК-1: умеет выбирать и обосновывать метрики с учетом задачи и свойств целевой переменной.	Расчет метрик и устное объяснение выбранного критерия.
4. ОПК-3: строит базовые модели регрессии и классификации и сравнивает их с простым исходным решением.	Практическая работа по построению и сравнению моделей.
5. ОПК-3: проводит вычислительный эксперимент на согласованных разбиениях данных и анализирует устойчивость результата.	Итоговый проект; проверка воспроизводимости эксперимента.
6. ОПК-3: интерпретирует ошибки модели, формулирует ограничения и представляет обоснованные выводы.	Письменный отчет и защита итогового проекта.

Соотнесение результатов обучения с формами организации занятий

Результат обучения	**Лекции**	**Практические**	**Самостоятельная работа**
1. ОПК-1: знает методы описательной статистики, типы признаков и принципы проверки качества данных.	+	+	+
2. ОПК-1: объясняет назначение преобразований признаков, правила разделения данных и причины утечки информации.	+	+	+
3. ОПК-1: умеет выбирать и обосновывать метрики с учетом задачи и свойств целевой переменной.	+	+	+
4. ОПК-3: строит базовые модели регрессии и классификации и сравнивает их с простым исходным решением.	+	+	+
5. ОПК-3: проводит вычислительный эксперимент на согласованных разбиениях данных и анализирует устойчивость результата.	+	+	+
6. ОПК-3: интерпретирует ошибки модели, формулирует ограничения и представляет обоснованные выводы.	+	+	+

4. Трудоемкость дисциплины в зачетных единицах с указанием количества академических часов, выделенных на контактную работу обучающегося с преподавателем (по видам учебных занятий) и на самостоятельную работу обучающегося

Трудоемкость — 3 зачетные единицы (108 академических часов). Семестр — 4. Форма промежуточной аттестации — экзамен.

№	Вид деятельности	4 семестр
1	Общая трудоемкость дисциплины	108
2	Контактная работа с преподавателем	54
3	в том числе лекции	18
4	в том числе практические занятия	36
5	Самостоятельная работа	54
6	в том числе выполнение практических работ	30
7	в том числе подготовка итогового проекта	12
8	в том числе подготовка к экзамену	12

Контактная работа составляет 54 часа. Подготовка к экзамену включена в самостоятельную работу; повторного учета часов в общей трудоемкости нет.

5. Содержание дисциплины, структурированное по темам (разделам) с указанием отведенного на них количества академических часов и видов учебных занятий

Ссылки в последнем столбце соответствуют нумерации результатов обучения в разделе 3.

Лекции (18 ч)

Наименование темы и ее содержание	Объем, час	Результаты обучения
Раздел 1. Постановка задачи и структура данных. Этапы аналитического исследования. Объект наблюдения, признаки и целевая переменная. Типы данных и шкалы измерений. Загрузка таблиц, проверка схемы, типов столбцов и единиц измерения. Формулирование исследовательского вопроса и критериев качества результата.	2	1, 2
Раздел 2. Разведочный анализ и визуализация. Описательные статистики, распределения и выбросы. Группировки и сводные таблицы. Гистограммы, диаграммы рассеяния и сравнение групп. Связь между признаками; различие статистической связи и причинного вывода. Выбор графика в соответствии с исследовательским вопросом.	2	1, 3
Раздел 3. Предобработка и построение признаков. Диагностика пропусков и дубликатов. Обоснование удаления и заполнения значений. Масштабирование числовых и кодирование категориальных признаков. Разделение данных до обучения преобразований. Конвейер предобработки и предупреждение утечки информации.	4	2, 3
Раздел 4. Базовые модели регрессии и классификации. Обучающая и проверочная выборки. Базовое предсказание и линейные модели. Линейная и логистическая регрессия, регуляризация и интерпретация коэффициентов. Сопоставление модели с простым базовым решением. Предпосылки метода и ограничения применимости.	4	4, 5
Раздел 5. Оценка качества и проверка устойчивости. Матрица ошибок, precision, recall и F1. Ошибки регрессии и выбор метрики с учетом задачи. Несбалансированные классы и выбор порога. Кросс-валидация и разделение подбора параметров и итоговой оценки. Сравнение методов на одинаковых разбиениях.	2	3, 5, 6

Наименование темы и ее содержание	Объем, час	Результаты обучения
Раздел 6. Воспроизводимое аналитическое исследование. Организация вычислительного эксперимента. Фиксация данных, параметров, версий библиотек и случайного состояния. Проверка воспроизводимости блокнота. Структура аналитического отчета, представление ограничений и защита выводов. Подготовка итогового проекта.	4	4, 5, 6

Практические занятия (36 ч)

Содержание практического занятия	Объем, час	Результаты обучения
Постановка задачи и структура данных. Составление паспорта набора данных и проверка корректности загрузки.	4	1, 2
Разведочный анализ и визуализация. Подготовка аналитической записки с визуализациями и интерпретацией распределений.	6	1, 3
Предобработка и построение признаков. Сравнение способов заполнения пропусков и проверка конвейера преобразований.	6	2, 3
Базовые модели регрессии и классификации. Построение базового решения и линейной модели с интерпретацией результата.	6	4, 5
Оценка качества и проверка устойчивости. Расчет метрик по истинным значениям и предсказаниям; анализ ошибок модели.	8	3, 5, 6
Воспроизводимое аналитическое исследование. Подготовка воспроизводимого блокнота, итогового отчета и презентации.	6	4, 5, 6

Самостоятельная работа (54 ч)

Виды самостоятельной работы	Объем, час	Результаты обучения
Постановка задачи и структура данных. Составление паспорта набора данных и проверка корректности загрузки.	6	1, 2
Разведочный анализ и визуализация. Подготовка аналитической записки с визуализациями и интерпретацией распределений.	8	1, 3
Предобработка и построение признаков. Сравнение способов заполнения пропусков и проверка конвейера преобразований.	8	2, 3
Базовые модели регрессии и классификации. Построение базового решения и линейной модели с интерпретацией результата.	8	4, 5
Оценка качества и проверка устойчивости. Расчет метрик по истинным значениям и предсказаниям; анализ ошибок модели.	6	3, 5, 6
Воспроизводимое аналитическое исследование. Подготовка воспроизводимого блокнота, итогового отчета и презентации.	6	4, 5, 6
Подготовка к экзамену: повторение теоретических вопросов и решение типовых задач.	12	1–6

6. Перечень учебной литературы

Основная литература:

- McKinney W. Python for Data Analysis. 3rd edition. 2022. Электронная версия: https://wesmckinney.com/book/ . Разделы о загрузке, очистке, группировке и визуализации данных.

- James G., Witten D., Hastie T., Tibshirani R., Taylor J. An Introduction to Statistical Learning: with Applications in Python. 2023. Материалы авторов: https://www.statlearning.com/ . Разделы о регрессии, классификации и оценке моделей.

Дополнительные материалы:

- VanderPlas J. Python Data Science Handbook. Электронная версия: https://jakevdp.github.io/PythonDataScienceHandbook/ . Разделы о NumPy, pandas, визуализации и машинном обучении.

Чтение сопровождается вопросами к соответствующей теме и заданиями на воспроизведение основных приемов на учебном наборе данных.

7. Учебно-методическое обеспечение самостоятельной работы

Самостоятельная работа включает выполнение практических заданий, чтение учебных материалов, подготовку проекта и повторение теоретических вопросов. Для каждой работы предоставляются описание данных, формулировка задачи, требования к отчету и критерии оценивания.

Раздел дисциплины	**Содержание самостоятельной работы**
Постановка задачи и структура данных	Составление паспорта набора данных и проверка корректности загрузки.
Разведочный анализ и визуализация	Подготовка аналитической записки с визуализациями и интерпретацией распределений.
Предобработка и построение признаков	Сравнение способов заполнения пропусков и проверка конвейера преобразований.
Базовые модели регрессии и классификации	Построение базового решения и линейной модели с интерпретацией результата.
Оценка качества и проверка устойчивости	Расчет метрик по истинным значениям и предсказаниям; анализ ошибок модели.
Воспроизводимое аналитическое исследование	Подготовка воспроизводимого блокнота, итогового отчета и презентации.

Отчет оформляется в Jupyter Notebook с последовательным исполнением ячеек, подписями графиков и пояснением принятых решений. Все внешние материалы сопровождаются ссылками. Подготовка к экзамену включает решение типовых задач и устное объяснение ограничений методов.

8. Перечень ресурсов сети Интернет

- Python for Data Analysis, открытая версия: https://wesmckinney.com/book/ .
- An Introduction to Statistical Learning, книги и учебные материалы: https://www.statlearning.com/ .
- Python Data Science Handbook: https://jakevdp.github.io/PythonDataScienceHandbook/ .
- Официальная документация Python, NumPy, pandas, Matplotlib и scikit-learn используется как справочный материал к практическим работам.

Материалы конкретной учебной группы, условия заданий и сроки сдачи размещаются преподавателем в электронной образовательной среде курса.

9. Информационные технологии и программное обеспечение

На практических занятиях используются Python, Jupyter Notebook или JupyterLab, библиотеки NumPy и pandas для обработки таблиц, Matplotlib для визуализации и scikit-learn для предобработки и моделирования.

Перед началом работы преподаватель предоставляет файл окружения с согласованными версиями библиотек. Обучающиеся сохраняют сведения о версиях, фиксируют случайное

состояние алгоритмов и проверяют исполнение блокнота с чистого запуска. Для обмена результатами используются форматы CSV, IPYNB и PDF. Сетевые сервисы не должны быть обязательным условием выполнения вычислительной части задания.

10. Материально-техническое обеспечение

Для лекций требуется аудитория с проектором и возможностью демонстрации программного кода и визуализаций. Для практических занятий необходим компьютерный класс либо индивидуальные компьютеры обучающихся с установленным учебным окружением.

Учебные задания рассчитаны на обработку табличных данных на обычном процессоре; специализированный графический ускоритель не требуется. До занятия проверяются доступность файлов данных, права на запись результатов и возможность локального запуска Jupyter. Для самостоятельной работы предоставляются инструкции по установке окружения и архив исходных материалов.

11. Оценочные средства и порядок проведения аттестации

11.1 Текущий контроль и промежуточная аттестация

Текущий контроль включает три практические работы и итоговый проект. Практическая работа 1 посвящена разведочному анализу, работа 2 — подготовке данных, работа 3 — сравнению моделей и метрик. Каждая работа сдается в виде исполняемого блокнота и краткой аналитической записки; преподаватель задает вопросы по принятым решениям.

Экзамен состоит из теоретического вопроса, разбора аналитической ситуации и обсуждения итогового проекта. Обучающийся объясняет выбор метода, воспроизводит ключевые вычисления и формулирует ограничения результата. Вопросы охватывают все разделы дисциплины.

11.2 Критерии и шкала оценивания

Оценка за дисциплину складывается из результатов практических работ (45 баллов, по 15 за каждую), итогового проекта (25 баллов) и экзамена (30 баллов). Максимальный результат — 100 баллов. Для положительной итоговой оценки необходимо набрать не менее 15 баллов за экзамен.

Критерий	Показатели достижения
Корректность работы с данными	Проверены типы, пропуски и дубликаты; преобразования обоснованы; данные разделены до обучения преобразований.
Обоснованность модели и метрик	Построено исходное решение; метрики соответствуют задаче; сравнение проводится на одинаковых разбиениях.
Воспроизводимость	Блокнот выполняется с чистого запуска; сохранены параметры, случайное состояние и сведения об окружении.
Интерпретация	Выводы опираются на расчеты и графики; рассмотрены ошибки и ограничения; отсутствуют необоснованные причинные утверждения.

Итоговый балл	Оценка
85–100	Отлично
70–84	Хорошо
55–69	Удовлетворительно
0–54 либо не выполнен минимум экзамена	Неудовлетворительно

11.3 Типовые задания и материалы для контроля

Задание 1. Разведочный анализ

Для выданной таблицы измерений сформулировать исследовательский вопрос, проверить типы и диапазоны признаков, построить описательные статистики и визуализации. Объяснить обнаруженные особенности распределений и предложить план дальнейшей обработки. Представить блокнот и аналитическую записку; каждый график должен отвечать на сформулированный вопрос.

Задание 2. Предобработка данных

На учебной таблице с числовыми и категориальными признаками исследовать пропущенные значения. Сравнить два обоснованных способа обработки, организовать преобразования в конвейер и показать, что параметры преобразований оцениваются

только по обучающей части. Представить обработанные данные, исполняемый блокнот и обоснование выбора метода.

Задание 3. Качество классификации

По таблице истинных меток и прогнозных вероятностей построить матрицу ошибок, рассчитать precision, recall и F1, сравнить несколько порогов. Объяснить, как дисбаланс классов влияет на выводы. Представить таблицу метрик, расчет и рекомендацию по выбору порога с учетом цены разных ошибок.

Итоговый проект

Выполнить полный цикл анализа выбранного учебного набора: описать данные и задачу, подготовить признаки, построить исходное решение и модель, провести проверку качества и анализ ошибок. Приложить сведения об окружении, воспроизводимый блокнот и итоговый отчет. В защите требуется обосновать выбор решений и указать ограничения применимости результата.

Примеры вопросов к экзамену:

- Почему заполнение пропусков до разделения данных может приводить к утечке информации?
- Чем различаются назначение проверочной выборки и итоговой тестовой выборки?
- В какой ситуации высокая доля правильных ответов не отражает полезность классификатора?
- Какие сведения необходимо сохранить для воспроизведения вычислительного эксперимента?

Лист актуализации рабочей программы дисциплины

Дата	Изменения	Разработчик	Подпись